



ARCHITETTURE DATI · A.A. 2025–2026

Valutazione delle performance di modelli di Machine Learning in seguito a sporcamento dei dati

Gabriel Pesce · 899638 ·

Repository di progetto: <https://github.com/zFishStick/Progetto-Architetture-Dati>

Università degli Studi di Milano-Bicocca · Laurea Magistrale in Informatica

Obiettivo del progetto

Valutare le prestazioni di due modelli di Machine Learning e verificare come lo sporcamiento del dataset, la degradazione volontaria dei dati, comprometta e degradi le metriche di valutazione.

Tre tecniche di sporcamiento analizzate, applicate in modo incrementale su 5 scenari ciascuna.



1. Inserimento di rumore

Aggiunta di rumore gaussiano alle variabili numeriche



2. Rimozione di feature

Eliminazione casuale di variabili dal dataset



3. Sostituzione di valori

Rimpiazzo dei dati con valori casuali

Analisi del Dataset “Census Income”

Conosciuto anche come **Adult dataset**, è molto popolare per la classificazione binaria. L'obiettivo è prevedere se il reddito annuo di una persona supera o meno i **\$50.000**.

**48.842**

istanze totali

**14**

feature (numeriche + categoriche)


**7,41%**righe con ≥ 1 valore nullo

Variabile target · income

 $\leq 50K$ · 76,1% **$> 50K$ · 23,9%**

Dataset moderatamente sbilanciato

Matrice di Collinearità



La **Matrice di Collinearità** verifica l'esistenza di correlazioni tra le feature del dataset.

Correlazioni **più alte**:

- *education e education-num* (1.0)
- *marital-status e relationship* (0.68)
- *race e native-country* (0.69)
- *relationship e sex* (0.84)
- *workclass e occupation* (0.73)

Le restanti feature presentano correlazione < 0.50 , la più piccola è *fnlwgt* (0.01)

Pulizia e Codifica del Dataset



1. Valori nulli

I '?' e i NaN sostituiti con la dicitura Unknown, senza rimuovere alcun record.



2. Target unificato

I 4 valori (errore di formattazione) ridotti a $\leq 50K \rightarrow 0$ e $> 50K \rightarrow 1$.



3. Riduzione dataset

Rimosse fnlwgt, race, native-country, education, relationship, workclass per bassa correlazione o ridondanza.



4. Codifica categoriche

sex mappata in binario; marital-status e occupation tramite One-Hot Encoding (14 $\rightarrow$ 26 feature).



5. Standardizzazione

Variabili numeriche portate a media 0 e dev. std 1, dopo Hold-Out stratificato 80/20.



Split stratificato

Entrambi i set mantengono la stessa proporzione delle classi, evitando di amplificare lo sbilanciamento.

Confronto tra i modelli



Support Vector Machine

Si basa sull'ipotesi di margine massimo: cerca l'iperpiano che massimizza la distanza tra le classi nello spazio delle feature.

PARAMETRI

- `max_iter` = 10000
- `C` = 1.0
- `class_weight` = balanced



Random Forest

Una "foresta" di alberi decisionali che combina le previsioni di più alberi per migliorare la precisione e ridurre l'overfitting.

PARAMETRI

- `n_estimators` = 100
- `n_jobs` = -1
- `class_weight` = balanced

I due modelli sono stati scelti per curiosità personale: due algoritmi con strategie decisionali diverse e mai usati in progetti precedenti.

Baseline sui dati puliti



Metriche sulla classe minoritaria > 50K

LETTURA DEI RISULTATI

Random Forest

Accuracy più alta (0,84 vs 0,80) e Precision migliore: poche previsioni positive, ma più affidabili.

SVM

Recall eccellente (0,84): individua meglio la classe positiva, ma con più falsi positivi.

F1-Score

Identico per entrambi (0,67): strategie diverse, previsioni equivalenti.

Sporcamento del dataset

Per ciascuna tecnica utilizzata, è stata usata la tecnica **Repeated Hold-Out Validation**.

Per ottenere dei risultati più affidabili rispetto a una singola esecuzione, sono state effettuate **20** iterazioni, ciascuna con uno **split** del dataset differente. Inoltre, è stata calcolata la **media aritmetica** di ciascuna metrica ottenuta ed è stato calcolato **l'intervallo di confidenza** in modo da misurare la variabilità dei risultati tra le diverse iterazioni e garantire che eventuali variazioni di performance siano statisticamente significative e non casuali.



1. Inserimento di rumore

Aggiunta di rumore gaussiano alle variabili numeriche. Impatta sull'accuratezza dei dati.



2. Rimozione di feature


Eliminazione casuale di variabili dal dataset. Impatta sulla completezza dei dati.



3. Sostituzione di valori

Rimpiazzo dei dati con valori casuali. Impatta sull'accuratezza ma mantenendo la validità dei dati (vengono solo sostituiti, non alterati).

Inserimento di rumore gaussiano



Andamento della Precision (classe > 50K) su 5 livelli di rumore



SVM · calo graduale

Degrado lineare e proporzionale all'aumento del rumore (Precision 0,556 → 0,495).



Distanze spaziali che si spostano lentamente.



Random Forest · andamento irregolare

Andamento a picchi: la Precision sale a 0,712 a rumore 0,5. Le soglie rigide dei nodi spostano interi gruppi di istanze.

Inserimento di rumore gaussiano



Rimozione casuale delle feature



Test	Feature rimosse	F1 · SVM	F1 · RF
1	age	0.663	0.671
2	occupation, education-num, capital-loss	0.606	0.628
3	education-num	0.654	0.659
4	age, sex_encoded, capital-loss, education-num	0.642	0.656
5	capital-gain, age	0.642	0.633

Le feature rimosse sono identiche per i due modelli.





Le feature più impattanti

education-num e **occupation**


La rimozione combinata (Test 2) produce il calo più marcato: F1 SVM a 0,606. Precision crolla a 0,46, Recall sale a 0,88 → tanti falsi positivi.

Il Test 1 non ha prodotto cambiamenti, la variabile 'age' viene compensata dalle altre feature, indicando che 'age' è poco impattante sui risultati.

Rimozione casuale delle feature



Sostituzione con valori casuali



Random Forest: l'Accuracy resta alta mentre la Recall crolla



Degrado graduale



Shuffling delle numeriche e swap delle categoriche One-Hot. Entrambi i modelli calano in modo continuo, senza anomalie.



Accuracy ingannevole

Sui dati sbilanciati l'Accuracy subisce un leggero calo, restando però sempre alta. Al contrario, La Recall è l'indicatore reale del degrado.

Sostituzione con valori casuali



CONCLUSIONI



Cosa ci dice lo sporcamento



SVM più affidabile

Calo sempre graduale; la Random Forest è più instabile per le sue soglie rigide. In scenari reali con dati non garantiti, la SVM è la scelta più solida.



Feature determinanti

education-num e occupation sono i predittori chiave: la loro rimozione compromette la separazione tra le classi. Le feature secondarie (age) pesano poco.



Accuracy $\neq$ qualità

Su dataset sbilanciati l'Accuracy maschera il degrado reale: la Recall sulla classe minoritaria è la metrica più sensibile e affidabile.

Sviluppi futuri: dataset più bilanciato · ulteriori tecniche (duplicazione, outlier) · nuovi modelli (reti neurali, Naive Bayes)

Gabriel Pesce · 899638

Grazie per l'attenzione!