



UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA

Scuola di Scienze

Dipartimento di Informatica, Sistemistica e Comunicazione

Corso di laurea Magistrale in Informatica

Architetture Dati

Valutazione delle performance di modelli di Machine
Learning in seguito a sporcamento dei dati

Gabriel Pesce - 899638

Anno Accademico 2025 - 2026

Indice

1	Introduzione	2
1.1	Obiettivo del Progetto	2
1.2	Setup dell'ambiente e strumenti utilizzati	3
2	Analisi Esplorativa del Dataset	4
2.1	Descrizione del Dataset	4
2.2	Distribuzione delle variabili	6
2.3	Valori nulli	8
2.4	Matrice di Collinearità	9
3	Preprocessing	11
3.1	Sostituzione dei valori nulli	11
3.2	Unificazione della variabile target	11
3.3	Riduzione del dataset	11
3.4	Codifica delle variabili categoriche	13
3.5	Standardizzazione dei dati	13
4	Fase di Modellazione	14
4.1	Modelli utilizzati	14
4.2	Baseline dei modelli	15
5	Fase di Sporramento del Dataset	17
5.1	Inserimento di rumore nei dati	17
5.2	Rimozione casuale delle feature	19
5.3	Sostituzione con valori casuali	21
6	Conclusioni	24
6.1	Analisi comparativa dei modelli	24
6.2	Feature più impattanti	24
6.3	Efficacia delle tecniche di sporramento	25
6.4	Sviluppi futuri	25

Chapter 1

Introduzione

Una nota riguardo l'uso dell'IA

Per questioni di correttezza, è necessario specificare che è stato fatto uso di Intelligenza Artificiale per questo progetto come **strumento di supporto** e non a scopo **generativo**.

Tutto il contenuto scritto all'interno della relazione è stato fatto **interamente dal sottoscritto**. Le fasi di progetto, dall'esplorazione dei dati e la modellazione, sono frutto di attività pregresse svolte in altri corsi in aggiunta di nozioni imparate durante lo svolgimento di questo progetto.

L'uso dell'IA è stato applicato per operazioni più meccaniche quali la **creazione dei grafici in Python**, e per **ottenere informazioni aggiuntive** riguardo il comportamento dei modelli e il loro approccio predittivo, dato che molto spesso le documentazioni risultano vaghe e complicate da interpretare.

Per concludere, è stata utilizzata in fase finale per **verificare la correttezza sintattica e grammaticale del contenuto**, senza alterare in modo significativo il contenuto scritto.

1.1 Obiettivo del Progetto

Il seguente progetto ha lo scopo di valutare le prestazioni di due modelli di Machine Learning e verificare come lo sporcamento del dataset comprometta e degradi le metriche di valutazione.

Per **Sporcamento dei Dati** si intende una tecnica volta a degradare volontariamente il dataset. Tra le possibili operazioni troviamo:

1. **Aggiunta di rumore ai dati**: variare in modo minimo o significativo il valore numerico delle variabili sommandolo a un numero fisso che prende il nome di *rumore*.
2. **Rimozione casuale di feature**
3. **Sostituzione di dati con valori casuali**

1.2 Setup dell'ambiente e strumenti utilizzati

Per la codifica del progetto è stato utilizzato il linguaggio di programmazione **Python** dato che risulta uno dei linguaggi più utilizzati nell'ambito del Machine Learning e dell'analisi dei dati, questo grazie alle librerie che offre.

Diverse librerie sono state usate per questo progetto

- **scikit-learn:** popolare libreria dedicata al Machine Learning e all'analisi dei dati.
- **pandas:** una libreria dedicata alla manipolazione dei dati strutturati in tabelle con diversi formati (es. CSV).
- **matplotlib:** libreria dedicata alla visualizzazione dei dati sotto forma di grafici (es. istogrammi, grafici a barre...)
- **numpy:** libreria creata per il calcolo scientifico e la gestione efficiente di grandi array e matrici multidimensionali.

Chapter 2

Analisi Esplorativa del Dataset

2.1 Descrizione del Dataset

Per il seguente progetto, è stato selezionato il dataset **Census Income**¹, ottenibile da siti come *UCI Machine Learning* o *Kaggle*.

Il dataset, precedentemente conosciuto come *Adult dataset*, è molto popolare nel campo del Machine Learning per compiti di classificazione binaria. Il suo scopo principale è **prevedere se il reddito annuo di una persona supera o meno i \$50.000**.

Il dataset contiene un totale di **48.842 istanze**, ciascuna contenente **14 feature**, distinte tra variabili **numeriche**, quindi sotto forma di numeri, e **categoriche**, sotto forma di stringhe.

¹Il dataset è ottenibile dal seguente link: <https://archive.ics.uci.edu/dataset/20/census+income>

Nome Feature	Tipo	Descrizione
age	Numerica	Età dell'individuo espressa in anni.
workclass	Categorica	La categoria contrattuale o la natura giuridica del datore di lavoro (es. dipendente privato, statale, autonomo).
fnlwgt	Numerica	Peso statistico; indica quante persone reali nella popolazione americana sono rappresentate da questo singolo record.
education	Categorica	Il massimo titolo di studio conseguito.
education-num	Numerica	Gli anni totali di studio completati.
marital-status	Categorica	Lo stato civile della persona al momento del censimento (es. sposato, divorziato, mai sposato).
occupation	Categorica	Il tipo di occupazione o mansione lavorativa svolta dall'individuo.
relationship	Categorica	Il ruolo ricoperto dalla persona all'interno del nucleo familiare (es. marito, moglie, figlio).
race	Categorica	L'etnia o il gruppo razziale di appartenenza.
sex	Categorica	Il genere biologico della persona (Maschio o Femmina).
capital-gain	Numerica	Guadagni finanziari extra derivanti da investimenti o vendite di proprietà.
capital-loss	Numerica	Le perdite finanziarie subite su investimenti o vendite di proprietà.
hours-per-week	Numerica	Il numero medio di ore lavorate ogni settimana.
native-country	Categorica	La nazione di nascita o di origine dell'individuo.


Table 2.1: Descrizione e tipologia delle variabili presenti nel dataset.

La variabile target è **income**, una variabile categorica che stabilisce per ogni persona nel dataset possiede un reddito annuo minore (o pari) o maggiore di \$50.000.

2.2 Distribuzione delle variabili

Le Figure 2.1 e 2.2 mostrano la distribuzione delle feature nel dataset.


Figure 2.1: Distribuzione delle variabili numeriche



Dai grafici delle variabili numeriche, si osserva che:

- **age** mostra una distribuzione più o meno normale, con una discesa graduale verso le età più avanzate.
- **hours-per-week** mostra valori molto bassi, con un picco intorno alle 40 ore, che è tipico per una settimana lavorativa standard.
- **fnlwgt** è distribuito solo su una parte del grafico, interrompendosi poco prima di 0.8.
- **education-num** mostra tre picchi distinti, corrispondenti a diversi livelli di istruzione, in particolare a 9, 10 e 13 anni di istruzione.
- **capital-gain** e **capital-loss** mostrano una distribuzione altamente asimmetrica, con la maggior parte dei valori concentrati vicino a zero e pochi valori che rappresentano guadagni o perdite significative.

Figure 2.2: Distribuzione delle variabili categoriche




Dai grafici delle variabili categoriche, si osserva che:

- **workclass** è dominato da dipendenti privati (Private).
- **education** il titolo di studio più diffuso è il diploma di scuola superiore (HS-grad). Seguono un elevato numero di individui con studi universitari parziali/incompleti (Some-college) e persone in possesso di una laurea di primo livello (Bachelors).
- **marital-status** è dominato da persone sposate (Married-civ-spouse) e da persone che non si sono mai sposate (Never-married).
- **occupation** mostra una prevalenza di persone impiegate in mansioni di artigianato (Craft-repair) o carriere professionali (Prof-specialty).
- **relationship** è dominato da persone che ricoprono il ruolo di marito (Husband) e da persone che non sono in una relazione familiare (Not-in-family).
- **race** mostra una prevalenza di persone di etnia bianca (White), seguita da persone di etnia nera (Black).
- **sex** è dominato da persone di genere maschile (Male).
- **native-country** mostra una prevalenza di persone nate negli Stati Uniti (United-States), seguite da persone nate in India (India) e in Messico (Mexico).

All'interno di alcuni grafici, in particolare in quello di **workclass**, **occupation** e **native-country**, alcuni tipi delle variabili hanno valore ?, dato che si tratta di una formattazione errata, nella fase di preprocessing verranno rimappati, in modo che i modelli siano in grado di rilevare qualora si trattasse di un valore nullo.

Figure 2.3: Distribuzione della variabile target



La Figura 2.3 mostra la distribuzione della variabile target *income*, mostrando un forte sbilanciamento. Il **76.1%** delle persone nel dataset possiede un reddito annuo minore o pari a \$50.000, contro il restante **23.9%** con reddito maggiore di \$50.000.

Le percentuali mostrate sono state calcolate dopo l'unione dei target duplicati, dal momento che per un errore di formattazione restituiva 4 risultati causati da un punto presente alla fine di due variabili. I due risultati ridondanti sono stati unificati in $\leq 50K$ e $> 50K$, rispettivamente.

2.3 Valori nulli

Nel dataset sono presenti **2203** valori nulli con valore NaN, distribuiti nelle variabili *workclass*, *occupation* e *native-country*.

Come mostrato in Figura 2.2, si è verificata la presenza di valori nulli rappresentati con il simbolo ?, con un totale di **4262** valori distribuiti nelle stesse variabili. In totale, quindi, nel dataset sono presenti **6465** celle con valori nulli.

Per avere una visione più chiara sulla percentuale di persone con almeno un valore nullo, è stato fatto un controllo su tutte le righe del dataset, fornendo i seguenti risultati:

- In totale, considerando i valori nulli NaN e '?', il totale di righe coinvolte, e quindi contenente almeno un valore nullo, è pari a **3620**.
- Le features *workclass* e *occupation* hanno una percentuale di righe coinvolte di circa il **5.75%**
- La feature con meno valori nulli è *native-country*, con valore pari al **1.75%**


In totale, per l'intero dataset, il **7.41%** delle persone hanno almeno un valore nullo. Per quanto si tratti di una percentuale prettamente bassa, nella fase di preprocessing è stata applicata un'operazione di sostituzione, dove i valori nulli assumeranno valore *Unknown*.

2.4 Matrice di Collinearità

In questa sezione verifichiamo l'esistenza di correlazioni tra le feature del dataset. Lo scopo è identificare eventuali relazioni tra le variabili che potrebbero influenzare la costruzione del modello di classificazione.

Una nota importante: La matrice di correlazione prevede l'analisi delle sole variabili numeriche (dal momento che la scala di cui fa uso è quella di Pearson). Per ovviare al problema, è stata usata una libreria apposita chiamata **phik**², realizzata appositamente per calcolare la correlazione tra variabili categoriche e numeriche.

Figure 2.4: Matrice di Correlazione



Le variabili maggiormente correlate tra loro sono:

- **education** e **education-num** (1.0): correlazione perfetta, il che è prevedibile dato che **education-num** rappresenta gli anni di istruzione, mentre **education** rappresenta il titolo di studio in forma categorica.
- **marital-status** e **relationship** (0.68): correlazione mediamente alta. L'istogramma della feature **relationship** registra un numero elevato di mariti (Husband), mentre

²<https://pypi.org/project/phik/>

`marital-status` conta un numero elevato di persone sposate (Married-civ-spouse); è quindi logico che queste due variabili presentino una forte dipendenza.

- `race` e `native-country` (0.69): correlazione mediamente alta. L'istogramma della feature `race` mostra una netta maggioranza di persone di etnia bianca (White), mentre `native-country` conta un numero elevato di persone nate negli Stati Uniti (United-States).
- `relationship` e `sex` (0.84): correlazione molto alta. L'istogramma della feature `relationship` indica un numero elevato di persone che ricoprono il ruolo di marito (Husband), il che si allinea perfettamente con la forte presenza di individui di genere maschile (Male) nella feature `sex`.
- `workclass` e `occupation` (0.73): correlazione mediamente alta.

Riguardo la variabile target `income`, si possono fare le seguenti osservazioni:

Solo una variabile presenta una correlazione moderatamente alta, ovvero `relationship` con correlazione pari a 0.62.

Alcune di esse raggiungono una correlazione moderata (> 0.3):

- `sex` (0.33)
- `hours-per-week` (0.36)
- `capital-gain` (0.38)
- `age` (0.41)
- `marital-status` (0.42)
- `education` (0.46)
- `education-num` (0.47)

Queste variabili (esclusa `relationship` poiché altamente correlata con altre variabili indipendenti) sono le più importanti, in quanto influenzano maggiormente la variabile target `income`.

Altre variabili con minor correlazione (< 0.3) con `income` sono:

- `workclass` (0.17)
- `capital-loss` (0.26)

Al contrario, le variabili meno correlate in assoluto sono:

- `fnlwgt` (0.01)
- `race` (0.08)
- `native-country` (0.12)

Al fine di addestrare il modello in modo ottimale, alcune feature tra le meno correlate col target, o che risultano altamente correlate con altre variabili indipendenti, verranno rimosse nella fase di pre-processing. Questa scelta è motivata dal fatto che tali variabili non forniscono informazioni utili per la previsione del target `income`, oppure introducono ridondanza nel modello.

Chapter 3

Preprocessing

Nel seguente Capitolo sono mostrate tutte le operazioni riguardo il preprocessing del dataset, in modo da restituire un nuovo set ripulito e pronto per essere utilizzato dai modelli.

3.1 Sostituzione dei valori nulli

Durante l'analisi esplorativa (Capitolo 2), è stato attestato che il **7.41%** delle persone nel dataset contengono almeno un valore nullo, selezionato dai candidati `workclass`, `occupation` e `native-country`.

Nonostante sia una piccola percentuale, si è scelto di voler mantenere questi valori, applicando una semplice sostituzione. Prima di applicare questa sostituzione, i valori '?' sono stati prima rimpiazzati con NaN, per poi venire sostituiti dalla dicitura *Unknown*. L'approccio garantisce che nessun record del set venga rimosso, mantenendo la dimensione originale.

3.2 Unificazione della variabile target

Inizialmente, la variabile `target` restituiva quattro valori: `<=50K`, `>50K`, `<=50K.`, e `>50K.`. Per uniformare i dati, i valori `<=50K.` e `>50K.` sono stati unificati rispettivamente in `<=50K` e `>50K`. A seguire, la variabile `target` è stata trasformata in formato numerico, con `<=50K` mappato a 0 e `>50K` mappato a 1.

3.3 Riduzione del dataset

Per ridurre il dataset, sono state rimosse le variabili `fnlwgt`, `race` e `native-country`, in quanto presentano una correlazione molto bassa con la variabile target `income`.

La variabile `education` è stata rimossa in quanto è completamente correlata con `education-num`; quest'ultima, essendo numerica, risulta più adatta per la modellazione rispetto alla sua controparte categorica.

Anche la variabile `relationship` è stata rimossa, in quanto altamente correlata con `sex` e `marital-status`. La prima (`sex`), essendo più semplice da interpretare, è stata ritenuta

più adatta per la modellazione.

Infine, la variabile `workclass` è stata rimossa in quanto mediamente correlata con `occupation`; quest'ultima, essendo più descrittiva dato che specifica l'effettivo lavoro della persona, è risultata più adatta per la fase di modellazione.

La Figura 3.1 mostra la matrice di collinearità dopo la rimozione delle variabili.




Figure 3.1: Matrice di Correlazione dopo la riduzione

3.4 Codifica delle variabili categoriche

Dopo la riduzione del dataset, sono state modellate alcune variabili categoriche per favorire la comprensione del modello. Le feature in formato numerico risultano più facili da manipolare da parte del modello rispetto al formato categorico.

1. La feature `sex`, in quanto variabile binaria, è stata mappata in modo da poter restituire *1* per *Male* e *0* per *Female*.
2. Le feature `marital-status` e `occupation`, dato che possono restituire più di due valori, sono stati codificati mediante la tecnica di **One-Hot Encoding**: questo approccio, crea molteplici variabili binarie per ogni categoria presente in ciascuna di queste feature.

In seguito all'inserimento delle variabili binarie, la dimensione del dataset (precedentemente ridotto) è passato da 14 feature a 26 feature. Esempi di nuove feature sono `marital-status_Married-AF-spouse`, `occupation_Handlers-cleaners...`

3.5 Standardizzazione dei dati

All'interno del dataset sono presenti variabili numeriche caratterizzate da range di valori molto ampi; ad esempio, `capital-gain` presenta valori che spaziano da poco meno di 5000 fino a superare quota 40000.

Alcuni algoritmi (come la *SVM*) sono particolarmente sensibili a queste differenze di scala. Per risolvere il problema, è stata applicata la tecnica di **Standardizzazione**, che trasforma i dati affinché abbiano media 0 e deviazione standard 1. In questo modo, tutte le variabili numeriche vengono riportate sulla stessa scala, migliorando le prestazioni e la stabilità del modello.

Le variabili create mediante One-Hot Encoding non necessitano di essere standardizzate, in quanto, essendo variabili binarie, assumono esclusivamente i valori 0 e 1.

È importante sottolineare che, prima ancora di standardizzare i dati, è stata applicata la tecnica di **Hold Out Validation**, che permette di separare le istanze in un insieme di training e uno di test. Si è scelto di seguire l'approccio più comune, assegnando in modo stratificato l'**80%** dei dati al training set e il restante **20%** al test set. Tramite **stratificazione**, entrambi i set contengono una proporzione di istanze di ciascuna classe fedele a quella del dataset originale. Questa tecnica è fondamentale, in quanto il dataset preso in esame presenta uno sbilanciamento moderato tra le classi.

Chapter 4

Fase di Modellazione

In questo Capitolo vengono introdotti i due modelli usati per il progetto, i parametri utilizzati per ciascuno di essi e i risultati iniziali a seguito dell'addestramento sul dataset pulito. Questi risultati fungeranno da baseline per la fase successiva, ovvero la fase di sporcamento dei dati.

4.1 Modelli utilizzati

I modelli utilizzati sono stati la **Support Vector Machine (SVM)** e la **Random Forest**. La scelta di questi due algoritmi deriva da una curiosità personale, in quanto si tratta di modelli mai utilizzati in nessun progetto pregresso.

- La **SVM** verte sul concetto di ipotesi di margine massimo, cercando di trovare l'iperpiano che massimizza la distanza tra le classi nello spazio delle feature. Per il progetto, è stata utilizzata la **LinearSVC**, dato che offre prestazioni più alte per dataset più grandi.
- La **Random Forest** è una "foresta" di alberi decisionali, che combina le previsioni di più alberi per migliorare la precisione e ridurre il rischio di overfitting.

I parametri scelti per la SVM sono:

- **max_iter=10000**: Questo parametro imposta il numero massimo di iterazioni che l'algoritmo SVM eseguirà durante l'addestramento. Un valore più alto consente all'algoritmo di convergere su soluzioni più complesse, ma potrebbe richiedere più tempo di addestramento. Il valore di default è 1000, ma in questo caso è stato aumentato a 10000 per garantire una migliore convergenza.
- **C=1.0**: Questo parametro indica alla SVM quanto penalizzare gli errori di classificazione. Un valore più alto di C cerca di classificare correttamente tutti i punti di addestramento, mentre un valore più basso consente una maggiore tolleranza agli errori, favorendo una maggiore generalizzazione del modello. Il valore di default è 1.0.

I parametri scelti per la Random Forest sono:

- **n_estimators=100**: Specifica il numero di alberi nella foresta. Un valore più alto generalmente porta a un modello più complesso e con prestazioni migliori, ma

richiede più tempo di addestramento.

- **n_jobs=-1**: Questo parametro consente di utilizzare tutti i processori disponibili per l'addestramento del modello, accelerando il processo. Un valore pari a -1 indica che usa tutti i processori disponibili nella macchina.

Per entrambi i modelli, è stato impostato il parametro *class_weight = balanced* in grado di gestire dataset sbilanciati, come in questo caso, assegnando automaticamente un peso maggiore alle classi meno rappresentate durante l'addestramento.

4.2 Baseline dei modelli

Al fine di valutare le prestazioni iniziali e fornire una baseline di riferimento, entrambi i modelli vengono addestrati sul dataset ridotto, codificato e standardizzato. I risultati ottenuti verranno usati nella fase successiva del progetto, ovvero lo sporcamento del dataset.




Figure 4.1: Matrici di Confusione dei modelli baseline

Modello	Classe / Media	Precision	Recall	F1-Score	Accuracy
SVM	0 ($\leq 50K$)	0.94	0.79	0.86	0.80
	1 ($> 50K$)	0.55	0.84	0.67	
	Macro Avg	0.75	0.81	0.76	
Random Forest	0 ($\leq 50K$)	0.90	0.89	0.90	0.84
	1 ($> 50K$)	0.67	0.68	0.67	
	Macro Avg	0.78	0.79	0.78	

Table 4.1: Confronto delle metriche di Baseline tra SVM e Random Forest

La Tabella 4.1 mostra i risultati generati dai due modelli a seguito della fase di addestramento sul dataset pulito e codificato.

A prima impressione, la Random Forest sembra restituire risultati superiori rispetto alla SVM, mostrando un'Accuracy globale più alta (0.84 contro 0.80 della SVM) e una Precision nettamente migliore sulla classe minoritaria >50K (0.67 contro 0.55). Tuttavia, analizzando le metriche di dettaglio, emerge una differenza nel comportamento dei due algoritmi.

La SVM presenta infatti una Recall eccellente per la classe >50K (0.84), molto superiore rispetto a quella della Random Forest (0.68). Questo indica che la SVM è molto più efficace nell'individuare le istanze positive, ma con un degrado della Precision, generando numerosi falsi positivi. Il motivo dell'alto Recall è dato maggiormente dallo sbilanciamento dei dati, e quindi non solo dal margine massimo che ha separato i dati. La Random Forest, al contrario, fa meno previsioni positive, ma quando le fa è più probabile che siano corrette.

L'F1-Score risulta identico (0.67) per entrambi i modelli sulla classe >50K, dimostrando che, pur con strategie decisionali diverse, le loro predizioni sono equivalenti.

Chapter 5

Fase di Sporcamiento del Dataset

Durante questa fase di progetto, verranno applicate diverse tecniche mirate allo sporcamiento del dataset. L'obiettivo è analizzare come le performance dei modelli peggiorano (o in casi particolari migliorano) a seguito del degradamento del dataset.

Sono state usate tre tecniche di sporcamiento del dataset:

1. Inserimento di rumore nei dati
2. Rimozione casuale delle feature
3. Sostituzione di valori casuali

Ciascuna tecnica agisce su una diversa caratteristica riguardo la qualità dei dati: l'inserimento di rumore gaussiano degrada l'**accuratezza** dei valori numerici, allontanandoli dal loro valore reale; la rimozione casuale delle feature degrada la **completezza**, eliminando informazione dal dataset; la sostituzione con valori casuali degrada l'**accuratezza** mantenendo però intatta la **validità**, dato che i valori vengono solamente scambiati ma non vengono alterati come accade per il rumore.

Per garantire l'affidabilità dei risultati è stato adottato un approccio di **repeated hold-out stratificato** (80%-20%): la stratificazione mantiene in entrambi i set le stesse porzioni della variabile target (circa 76%-24%), evitando che lo sbilanciamento venga amplificato dalla divisione casuale. L'esperimento viene ripetuto $n = 20$ volte, ciascuna con un seed diverso che genera una nuova suddivisione train/test, così da addestrare e valutare i modelli su porzioni differenti dei dati. I valori riportati nei grafici sono la **media** delle 20 esecuzioni, con le barre d'errore che rappresentano l'**intervallo di confidenza al 95%**: intervalli ristretti indicano risultati stabili e poco dipendenti dal singolo split. Per ogni scenario, inoltre, SVM e Random Forest vengono valutati sugli stessi dati corrotti, così che le differenze osservate siano attribuibili al modello e non a una diversa estrazione casuale. Infine, il parametro `class_weight=balanced` assicura che le metriche sulla classe minoritaria restino significative nonostante lo sbilanciamento.

5.1 Inserimento di rumore nei dati

Per **rumore** si fa riferimento a imprecisioni o informazioni prive di significato presenti nei dati che possono compromettere le performance dei modelli.

Per introdurre rumore sui dati, viene usato il **Rumore Gaussiano**, che consiste nell'aggiungere un valore casuale estratto da una distribuzione normale (gaussiana) a ciascun dato. Questo tipo di rumore è comunemente usato per simulare errori di misurazione o variazioni naturali nei dati.

Questo approccio è stato applicato solo alle variabili numeriche, in quanto è più adatto per introdurre rumore in dati continui.

Per valutare l'impatto del rumore sui modelli, sono creati 5 scenari, in cui viene introdotto un livello crescente di rumore sui dati (0, 0.5, 1.0, 2.0, 5.0). Si tiene traccia delle 4 metriche più importanti (Precision, Accuracy, Recall e F1-Score) in modo da mostrare in un grafico l'andamento di ciascuna metrica al variare del livello di rumore introdotto sui dati. L'approccio dei 5 scenari è stato riutilizzato anche per le successive due tecniche.




Figure 5.1: Impatto della SVM con l'aggiunta di Rumore Gaussiano (Classe 1)




Figure 5.2: Impatto della Random Forest con l'aggiunta di Rumore Gaussiano (Classe 1)

L'introduzione del Rumore Gaussiano sulle variabili numeriche ha generato un degrado prestazionale in entrambi i modelli, seppur con dinamiche differenti.

La **SVM** mostra un calo delle metriche più lineare e graduale. L'Accuracy, la Precision e l'F1-Score scendono in modo proporzionale all'aumento del rumore (l'Accuracy passa da 0.801 a 0.756 e l'F1-Score da 0.671 a 0.617). La metrica che subisce meno impatto è la Recall, la quale perde un numero piccolo di punti (circa 0.028, passando da un rumore nullo a un livello di scala 5), indicando che la SVM riesce comunque a mantenere una buona sensibilità nell'individuare la classe minoritaria.

La **Random Forest** risulta più irregolare, con picchi e discese non lineari, in particolar modo per quanto riguarda l'Accuracy e la Precision. Entrambe, anziché calare subito, registrano un rialzo in corrispondenza del livello di rumore 0.5: l'Accuracy sale da 0.835 a 0.839, mentre la Precision arriva persino a 0.712 (partendo da 0.652), per poi diminuire ai livelli di rumore successivi.

Gli intervalli di confidenza riportati (barre verticali mostrate per ogni punteggio) sono ristretti, confermando quindi la stabilità dei risultati. In particolare, il rialzo della Precision della Random Forest a rumore 0.5 si colloca al di fuori dell'intervallo del valore iniziale (a rumore 0) in modo nettamente ampio. Questo indica che il comportamento del modello è sistematico, e i risultati non sono generati da errori di campionamento o iterazioni "fortunate".

Questa variazione della Random Forest rispetto al calo semi-lineare della SVM si spiega analizzando il metodo di decisione dei due modelli. La SVM lavora massimizzando le distanze spaziali tramite un iperpiano: al minimo variare di un dato numerico a causa del rumore, la distanza cambia, allontanando gradualmente i punti dal confine corretto.

La Random Forest, al contrario, suddivide lo spazio decisionale basandosi su soglie matematiche all'interno dei nodi dell'albero. Se l'aggiunta di rumore sposta il valore di una feature, il modello non altera la sua classificazione finale a meno che quel nuovo valore non superi fisicamente la soglia di taglio di uno o più nodi. Questo meccanismo fa sì che interi gruppi di istanze cambino foglia di destinazione (e quindi classe predetta), generando i picchi visibili nei grafici.

5.2 Rimozione casuale delle feature

Mentre il Rumore Gaussiano ha coinvolto esclusivamente le variabili numeriche continue, la tecnica di rimozione casuale permette di testare la robustezza del modello anche rispetto alle variabili categoriche, non essendovi alcun vincolo di natura matematica.

La selezione delle feature da rimuovere è stata effettuata basandosi sulla matrice di correlazione. Nello specifico, sono state incluse le variabili che presentavano una correlazione da lieve a moderata con la variabile target *income*, in aggiunta a forti legami di multicollinearità con altre feature:

- *capital-loss* (corr = 0.26)
- *sex* (corr = 0.33)
- *hours-per-week* (corr = 0.36)
- *capital-gain* (corr = 0.38)
- *age* (corr = 0.41)
- *marital-status* (corr = 0.42)
- *occupation* (corr = 0.44)
- *education-num* (corr = 0.47)

Bisogna sottolineare che, per alcune variabili categoriche, in fase di preprocessing è stata applicata la codifica *One-Hot Encoding*, la quale ha comportato la creazione di nuove

colonne binarie per ciascuna categoria. Per garantire la coerenza logica dell'esperimento, è stato implementato un algoritmo di rimozione "a cascata": l'eliminazione di un concetto base (es. `occupation _...`) comporta la simultanea rimozione dell'intero blocco di variabili binarie da esso derivate, evitando incongruenze nei dati.

I risultati di cinque iterazioni di rimozione casuale sono visibili nelle Figure 5.3 e 5.4. Le feature rimosse sono uguali per entrambi i modelli, in modo da verificare la differenza prestazionale sulla stessa base delle variabili rimosse.

Test	Feature rimosse
1	age
2	occupation, education-num, capital-loss
3	education-num
4	age, sex_encoded, capital-loss, education-num
5	capital-gain, age

Table 5.1: Feature rimosse per ogni Test




Figure 5.3: Impatto su SVM dopo la rimozione delle feature (Classe 1)




Figure 5.4: Impatto su Random Forest dopo la rimozione delle feature (Classe 1)

L'osservazione dei grafici evidenzia come non tutte le variabili abbiano lo stesso peso strutturale all'interno degli algoritmi. L'impatto della rimozione, infatti, varia da un degrado quasi minimo a un calo più significativo delle prestazioni, in base alla natura delle feature rimosse in ciascuna iterazione. Come per il rumore gaussiano, è stato tenuto conto

dell'intervallo di confidenza (95%) di ciascuna metrica, così da mostrare la variabilità dei risultati sulle 20 iterazioni.

Il caso meno rilevante è il **Test 1**, in cui viene rimossa la sola feature **age**: entrambi i modelli mantengono prestazioni praticamente identiche alla baseline (F1-Score di 0.663 per la SVM e 0.671 per la Random Forest). Questo indica che l'informazione contenuta in **age**, presa singolarmente, non è determinante e viene compensata dalle altre feature correlate rimaste nel dataset.

Il caso più rilevante è invece il **Test 2**, che rimuove **occupation**, **education-num** e **capital-loss**. È il Test che impatta di più, in particolare sulla **SVM**, il cui F1-Score scende a 0.606 (il valore più basso tra tutti i test). Si nota inoltre un forte squilibrio tra le metriche: la Precision scende a 0.461 mentre la Recall sale a 0.883. In assenza di feature così informative, il modello tende a sbilanciarsi verso la classe positiva, individuando più veri positivi (Recall alta) ma generando molti falsi positivi (Precision bassa).

La **Random Forest** mostra lo stesso andamento, con il Test 2 e il Test 5 come iterazioni più impattanti, con valori di F1-Score molto vicini (0.628 e 0.633). Anche qui la Recall resta elevata (intorno a 0.80) a fronte di una Precision più bassa, coerentemente con quanto già osservato nella tecnica del Rumore Gaussiano.

Un confronto interessante è quello tra il **Test 3** (rimozione della sola **education-num**) e il **Test 1** (rimozione di **age**): la mancanza di **education-num** produce un calo più evidente (F1-Score di 0.654 per la SVM e 0.659 per la RF) rispetto a quella di **age**, che invece non aveva avuto effetti. Questo dimostra che **education-num** ha un peso predittivo maggiore rispetto ad **age**, in linea con la sua correlazione più alta con la variabile target.

Si può quindi evincere che feature come **education-num** e **occupation** costituiscono i pilastri decisionali primari per la distinzione tra le due classi di reddito: la loro rimozione, soprattutto se combinata (come nel Test 2), fa perdere ai modelli gran parte della capacità di separare le istanze in modo preciso. Al contrario, la rimozione di singole feature meno centrali, come **age**, non ha comportato variazioni importanti riguardo i risultati ottenuti.

Gli intervalli di confidenza risultano molto stretti per entrambi i modelli e per tutte le metriche: ciò indica che i risultati variano in misura trascurabile al cambiare della suddivisione train/test, e sono quindi stabili e affidabili. Gli intervalli sono stretti anche perché il dataset è molto grande: con un test set di circa 9.700 esempi, le metriche cambiano pochissimo a seconda di quale suddivisione 80/20 viene estratta.

5.3 Sostituzione con valori casuali

Per questa terza e ultima tecnica di iniezione del rumore, sono state selezionate le tre feature (utilizzate precedentemente nella fase di rimozione) maggiormente correlate con la variabile target **income**:

- **education-num** (corr = 0.47)
- **occupation** (corr = 0.44)
- **marital-status** (corr = 0.42)

L'obiettivo di questa tecnica è testare il degrado dei modelli a seguito della sostituzione dei dati con valori casuali, mantenendo intatta la struttura e i domini del dataset.

Per la variabile numerica (*education-num*), essendo i dati già standardizzati, l'approccio adottato è stato lo *shuffling* (permutazione) dei dati: i valori originali della feature vengono estratti e rimescolati tra le righe. In altre parole, si assegna in modo casuale il reale grado di istruzione di un utente a un altro utente, mantenendo inalterata la distribuzione statistica della colonna.

Per le variabili categoriche, a cui in fase di preprocessing era stata applicata la tecnica di *One-Hot Encoding*, l'approccio segue una logica più complessa. L'algoritmo individua il valore settato a 1 (che indica l'appartenenza alla categoria reale dell'utente), lo resetta a 0, e assegna casualmente il valore 1 a un'altra colonna dello stesso gruppo semantico. Ad esempio, lo spazio delle feature generato per l'occupazione comprende colonne binarie come *occupation_Sales*, *occupation_Craft-repair*, *occupation_Farming-fishing*, ecc.

Come per le tecniche precedenti, sono stati eseguiti 5 scenari basati sulla percentuale progressiva di istanze alterate (0%, 25%, 50%, 75% e 100%), per tracciare l'andamento di decadimento di ciascuna metrica.




Figure 5.5: Impatto su Support Vector Machine dopo la sostituzione dei valori (Classe 1)




Figure 5.6: Impatto su Random Forest dopo la sostituzione dei valori (Classe 1)

Per la **SVM**, il calo delle prestazioni risulta lineare e graduale. La metrica ad aver subito la variazione minore è l'Accuracy, con una perdita di 0.072 punti dal primo all'ultimo scenario. Al contrario, la Recall ha subito il maggior degrado, perdendo un totale di 0.150 punti.

La **Random Forest** mostra un andamento altrettanto graduale e regolare. A differenza di quanto osservato con il Rumore Gaussiano, in questo caso entrambi i modelli degradano in modo continuo, senza rialzi o anomalie. Anche per la Random Forest l'Accuracy è la metrica meno impattata (perdita di 0.041 punti), mentre la Recall è quella che cala di più, con un degrado di 0.216 punti: ben 0.066 punti in più rispetto alla SVM. Questo dato evidenzia che l'architettura ad alberi della Random Forest risulta maggiormente sensibile alla sostituzione casuale dei valori rispetto alla Support Vector Machine, in particolare nell'individuare la classe minoritaria.

Il motivo per cui l'Accuracy è la metrica meno impattata per entrambi i modelli è legato allo sbilanciamento del dataset: essendo calcolata su tutte le istanze, è dominata dalla classe maggioritaria ($\leq 50K$), che i modelli continuano a classificare in buona parte correttamente anche quando i dati si degradano. Di conseguenza l'Accuracy resta elevata e non riflette il reale degrado algoritmico, evidenziato invece dal forte abbassamento della Recall sulla classe minoritaria (Classe 1), calcolata solo su quest'ultima.

Anche per la sostituzione gli intervalli di confidenza risultano ristretti: il degrado misurato è stabile tra le 20 ripetizioni e poco dipendente dagli split. Inoltre, gli intervalli non si sovrappongono in modo rilevante, questo conferma che la progressiva perdita di prestazioni all'aumentare dei valori corrotti è un effetto sistematico, e non si tratta quindi di un fattore casuale.

Chapter 6

Conclusioni

In questo progetto è stato analizzato il comportamento dei due modelli selezionati in seguito a tre tecniche di sporcamento del dataset.

6.1 Analisi comparativa dei modelli

Per la Support Vector Machine, il calo delle performance è sempre stato prettamente graduale in tutte e 3 le tecniche, mentre la Random Forest è stato il modello ad aver mostrato un andamento più instabile e variabile a causa della sua architettura basata su soglie rigide, a eccezione della tecnica di sostituzione, dove l'andamento è stato graduale. In scenari reali dove la qualità del dato non è garantita, la SVM potrebbe quindi risultare una scelta più affidabile rispetto alla Random Forest.

6.2 Feature più impattanti

Il seguente dataset conteneva un totale di 14 feature. Dalla fase di sporcamento dei dati, in particolare dalla rimozione casuale delle feature, si è potuto evincere come alcune di esse siano i predittori più importanti per entrambi i modelli. Le feature più impattanti sono risultate `education-num` e `occupation`: la loro rimozione combinata (Test 2) ha prodotto il calo prestazionale più marcato per entrambi i modelli.

In particolare, `education-num` si conferma la variabile più rilevante, coerentemente con la sua correlazione più alta con il target: la sua rimozione singola (Test 3) ha avuto un impatto maggiore rispetto alla rimozione della sola `age` (Test 1), che invece non ha prodotto variazioni significative. Questo dimostra che non tutte le feature hanno lo stesso peso: la mancanza delle variabili più informative compromette sensibilmente la capacità dei modelli di separare le due classi di reddito, mentre la perdita di feature secondarie non produce variazioni impattanti per i modelli.

6.3 Efficacia delle tecniche di sporcamento

Le tre tecniche hanno evidenziato aspetti diversi:

- Il Rumore Gaussiano ha coinvolto solo variabili numeriche, mostrando sin da subito come i due modelli applicano algoritmi di predizione diversi: distanza spaziale della SVM e uso delle soglie della Random Forest.
- La rimozione casuale delle feature è la tecnica più diretta per osservare il peso reale di ciascuna feature, mostrando quali abbiano maggior valore nel dataset rispetto ad altre in base ai risultati ottenuti da ciascun modello.
- La sostituzione casuale ha mostrato come l'Accuracy sia una metrica ingannevole in presenza di dataset sbilanciati, mentre la Recall è l'indicatore più sensibile al degrado reale.

6.4 Sviluppi futuri

Per questo progetto, è stato selezionato un dataset contenente un **forte sbilanciamento** (76.1% - 23.9%). Un'idea potrebbe essere l'applicazione dello stesso obiettivo di progetto utilizzando un dataset più bilanciato e verificare come differiscono i risultati sia per il modello baseline sia per ciascuna tecnica di sporcamento.

Riguardo le tecniche di sporcamento, per il progetto ne sono state applicate 3, ma altre metodologie possono essere utilizzate, come la duplicazione dei dati, introduzione di outlier (dati all'infuori dei range prestabiliti).

Infine, per questo progetto sono stati utilizzati due modelli che fanno uso di due algoritmi diversi. Questo ha dato una visione di come le architetture di ciascun modello si adattano al dominio di allenamento. Un possibile sviluppo futuro è sicuramente l'implementazione di altri modelli, come reti neurali o classificatori Naive Bayes.